Pipeline de Données Pokémon & Dashboard Décisionnel

Architecture complète d'extraction automatisée, de stockage BigQuery et de restitution analytique pour l'optimisation e-commerce.

PRÉSENTÉ PAR

Brice

INFRASTRUCTURE GCP

GCP · BigQuery · GitHub Actions

VUE D'ENSEMBLE

Feuille de route

1. Cadrage Métier

Alignement des besoins e-commerce avec l'exploration des données produit de l'API PokéAPI.

2. Ingestion & Stockage

Collecte Python automatisée et structuration SQL dans Google Cloud et BigQuery.

3. Automation & CI/CD

Orchestration planifiée via GitHub Actions et sécurisation des accès par Secrets GCP (Google Cloud Platform).

4. Business Intelligence

Visualisation des KPI stratégiques et reporting opérationnel sur Data Studio.

Cadrage Métier : Boutique e-Commerce & Goodies

Problématique Commerciale

L'enseigne commercialise des produits dérivés et cartes à collectionner. Pour maximiser la rentabilité des stocks et affiner la campagnes publicitaires, ils doivent structurer les données produits selon la popularité et les caractéristiques physiques des créatures

Objectif : Transformer les données brutes de la PokéAPI en indicateurs exploitables pour l'approvisionnement et le marketing.

Gestion Prédictive des Stocks

Anticipation de la demande par typologie et caractéristiques physiques des produits.

Ciblage Marketing Précis

Priorisation des campagnes sur les articles à très forte expérience de base et notoriété.

EXTRACTION DATA

Source de Données & Ingestion via Python

script_extraction.py

Le script interroge la PokéAPI REST pour extraire la liste principale puis effectue des appels ciblés afin de récupérer les métriques physiques et attributs clés.

```
url = "https://pokeapi.co/api/v2/pokemon?limit=150"
response = requests.get(url)
# Structuration des attributs essentiels
rows.append({ "id": details["id"], "name": details["name"], "height":
details["height"], "weight": details["weight"], "type": details["types"][0]
["type"]["name"] })
```

Nettoyage & Normalisation

Filtrage immédiat des valeurs manquantes et élimination des doublons via Pandas avant l'envoi en base.

Performance

Chargement optimisé des 150 premiers Pokémon représentant le cœur du catalogue.

DATA WAREHOUSE

Stockage & Traitement SQL dans Google BigQuery

Table Raw Centralisée

Les données sont stockées dans la table `pokemon_db.raw_pokemon` au sein du projet Google Cloud.

Requêtage Découplé

Utilisation du connecteur moderne `pandas_gbq` pour exécuter des requêtes analytiques haute performance.

REQUÊTE D'AGRÉGATION PRINCIPALE

```
SELECT
  type,
  AVG(weight) as avg_weight,
  AVG(height) as avg_height
FROM `pokemon-api-511811.pokemon_db.raw_pokemon`
GROUP BY type
```

Cette vue permet de calculer instantanément le gabarit moyen par catégorie pour adapter le packaging des produits.

ANALYSES & INSIGHTS

Résultats SQL & Analyses de Notoriété

Top 5 Expérience de Base

L'analyse montre que les produits représentant les créatures les plus expérimentées génèrent le plus d'engagement chez les collectionneurs.

```
SELECT name, base_experience
ORDER BY base_experience DESC LIMIT 5
```

Distribution par Type

La ventilation par type révèle une nette prédominance des types Eau et Normal, guidant nos futurs volumes de commandes.

```
SELECT type, COUNT(*) as total
GROUP BY type ORDER BY total DESC
```

Automatisation avec GitHub Actions & Secrets

Planification Automatique (Cron)

Le workflow s'exécute automatiquement chaque lundi grâce à un déclencheur Cron sans aucune intervention humaine.

Sécurité GCP via GitHub Secrets

La clé JSON du Compte de Service est stockée de manière chiffrée dans la variable `GCP_CREDENTIALS`, évitant toute fuite dans le dépôt Git.

.github/workflows/pipeline.yml

```yaml
on:
  schedule: [{cron: '0 0 * * 1'}]
  workflow_dispatch:

jobs:
  run-pipeline:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v3
      - name: Run script
        env: GCP_CREDENTIALS: ${{ secrets.GCP_CREDENTIALS }}
```

QUALITÉ & ROBUSTESSE

Stratégie d’Idempotence & Intégrité des Données

Garantie Sans Doublon

L'utilisation du paramètre `if_exists="replace"` lors de l'envoi BigQuery garantit que l'exécution répétée du pipeline réécrira proprement la table.

Cette approche assure la parfaite idempotence de notre flux de données : peu importe le nombre de réexécutions, l'état final reste toujours propre et maîtrisé.

Reprise en Main sur Échec

En cas d'interruption réseau, le workflow peut être relancé manuellement via `workflow_dispatch` sans risque de corrrompre le Data Studio.

Maintenance Simplifiée

Aucune gestion complexe d'incréments ou de tables temporaires requise pour ce volume de données.

DATA VISUALIZATION

Restitution sur Data Studio

Barres Groupées : Gabarit

Superposition des métriques moyennes `AVG(weight)` et `AVG(height)` ventilées par type pour adapter la logistique.

Barres Horizontales : Top XP

Classement direct des 5 Pokémon phares ayant la plus forte valeur d'expérience pour orienter nos campagnes e-mailing.

Filtres Interactifs

Mise à disposition de filtres dynamiques par type permettant aux équipes métiers d'explorer librement les segments.

Merci de Votre Attention !

L'infrastructure automatisée est désormais opérationnelle pour piloter la stratégie e-commerce.

Avez-vous des questions ?